

# Параметрическое оценивание

## а) Метод моментов

Параметрические модели:

$$\mathfrak{F} = \left\{ f(x; \theta) : \theta \in \Theta \right\}$$

$\Theta \subset \mathbb{R}^k$  - пространство параметров,  $\theta = (\theta_1, \dots, \theta_k)$  - вектор параметров

$T(\theta)$  - значение, которое надо оценить

Пример:  $N(\mu, \sigma^2)$ ,  $\theta = (\mu, \sigma)$ . Если  $\mu$  необходимо оценить, то  $\mu = T(\theta)$ , а  $\sigma$  - мешающий параметр

**Пример:** пусть  $X_1, \dots, X_n \sim \text{Normal}(\mu, \sigma^2)$ .  $\theta = (\mu, \sigma)$  - параметр,  $\Theta = \{(\mu, \sigma) : \mu \in \mathbb{R}, \sigma > 0\}$  - пространство параметров.

Допустим, что измерения  $X_i$  - интегральная характеристика теста по исследованию крови. Задача состоит в том, чтобы  $\tau$  - долю наблюдений, для которых характеристика превышает 1. Пусть  $Z$  - стандартная нормальная случайная величина. Тогда

$$\begin{aligned} \tau &= \mathbb{P}(X > 1) = 1 - \mathbb{P}(X < 1) = 1 - \mathbb{P}\left(\frac{X - \mu}{\sigma} < \frac{1 - \mu}{\sigma}\right) \\ &= 1 - \mathbb{P}\left(Z < \frac{1 - \mu}{\sigma}\right) = 1 - \Phi\left(\frac{1 - \mu}{\sigma}\right) \end{aligned}$$

$\tau = T(\mu, \sigma) = 1 - \Phi((1 - \mu)/\sigma)$  - параметр, который необходимо оценить

**Пример:** пусть  $X$  имеет  $\text{Gamma}(\alpha, \beta)$  распределение, то есть

$$f(x; \alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x > 0,$$

3 где  $\alpha, \beta > 0$  и

$$\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y} dy$$

обозначает гамма-функцию.  $\theta = (\alpha, \beta)$  - параметр. Гамма-распределение обычно используют для моделирования времени жизни. Если задача состоит в том, чтобы оценить среднее время жизни, то

$$T(\alpha, \beta) = \mathbb{E}_\theta(X_1) = \alpha\beta$$

**Метод моментов – не оптимален; прост в использовании; полученные с помощью этого метода оценки могут использоваться в качестве начальных значений для более «тонких» алгоритмов**

**Пусть  $\theta = (\theta_1, \dots, \theta_k)$  - параметр. Для  $1 \leq j \leq k$  определим  $j$ -й момент согласно формуле**

4 
$$\alpha_j \equiv \alpha_j(\theta) = \mathbb{E}_\theta(X^j) = \int x^j dF_\theta(x)$$

**и  $j$ -й выборочный момент согласно формуле**

$$\hat{\alpha}_j = \frac{1}{n} \sum_{i=1}^n X_i^j$$

$\hat{\theta}_n$  - оценка параметра  $\theta = (\theta_1, \dots, \theta_k)$  на основе метода моментов, если

$$\alpha_1(\hat{\theta}_n) = \hat{\alpha}_1$$

$$\alpha_2(\hat{\theta}_n) = \hat{\alpha}_2$$

$$\vdots \quad \vdots \quad \vdots$$

$$\alpha_k(\hat{\theta}_n) = \hat{\alpha}_k$$

**Пример:**  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ . Тогда  $\alpha_1 = \mathbb{E}_p(X) = p$  и  $\hat{\alpha}_1 = n^{-1} \sum_{i=1}^n X_i$ , откуда

$$\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

**Пример:**  $X_1, \dots, X_n \sim \text{Normal}(\mu, \sigma^2)$ . Тогда

$$\alpha_1 = \mathbb{E}_\theta(X_1) = \mu$$

$$\alpha_2 = \mathbb{E}_\theta(X_1^2) = \mathbb{V}_\theta(X_1) + (\mathbb{E}_\theta(X_1))^2 = \sigma^2 + \mu^2$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 + \hat{\mu}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

Решая систему линейных уравнений, получаем, что

$$\hat{\mu} = \overline{X}_n$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

**Теорема.** Пусть  $\hat{\theta}_n$  - оценка параметра  $\theta$  с помощью метода моментов. Тогда (при определенных предположениях на распределение выборки):

1.  $\hat{\theta}_n$  существует с вероятностью 1

2.  $\hat{\theta}_n \xrightarrow{P} \theta$  при  $n \rightarrow \infty$

3. Оценка асимптотически нормальна, то есть

$$\sqrt{n}(\hat{\theta}_n - \theta) \rightsquigarrow N(0, \Sigma),$$

где  $\Sigma = g \mathbb{E}_\theta(YY^T)g^T$ ,  $Y = (X, X^2, \dots, X^k)^T$ ,

$g = (g_1, \dots, g_k)$  и  $g_j = \partial \alpha_j^{-1}(\theta) / \partial \theta$ .

**Замечание:** Последний пункт теоремы можно использовать для нахождения стандартных ошибок и доверительных интервалов

## **b) Метод максимального правдоподобия и его свойства**

Пусть задана i.i.d. выборка  $X_1, \dots, X_n \sim F$ , при этом у распределения имеется плотность  $f(x; \theta)$

Функция правдоподобия задается формулой

8

$$\mathcal{L}_n(\theta) = \prod_{i=1}^n f(X_i; \theta)$$

Логарифмическая функция правдоподобия задается формулой

$$\ell_n(\theta) = \log \mathcal{L}_n(\theta)$$

Будем рассматривать правдоподобие как функцию параметра

$$\mathcal{L}_n : \Theta \rightarrow [0, \infty)$$

Оценка максимального правдоподобия (ОМП оценка) определяется как такое значение  $\hat{\theta}_n$  параметра  $\theta$ , которое максимизирует  $\mathcal{L}_n(\theta)$



**Пример:** пусть  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ .

Распределение определяется по формуле  $f(x; p) = p^x(1 - p)^{1-x}$  при  $x = 0, 1$ .

$$9 \quad \mathcal{L}_n(p) = \prod_{i=1}^n f(X_i; p) = \prod_{i=1}^n p^{X_i} (1 - p)^{1-X_i} = p^S (1 - p)^{n-S},$$

где  $S = \sum_i X_i$ .

$$\ell_n(p) = S \log p + (n - S) \log(1 - p)$$

Откуда получаем, что ОМП оценка равна  $\hat{p}_n = S/n$ .

**Пример:** пусть  $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ .  $\theta = (\mu, \sigma)$  - параметр.

**Функция правдоподобия (без учета констант) имеет вид**

$$\begin{aligned}\mathcal{L}_n(\mu, \sigma) &= \prod_i \frac{1}{\sigma} \exp \left\{ -\frac{1}{2\sigma^2} (X_i - \mu)^2 \right\} \\ &= \sigma^{-n} \exp \left\{ -\frac{1}{2\sigma^2} \sum_i (X_i - \mu)^2 \right\} \\ &= \sigma^{-n} \exp \left\{ -\frac{nS^2}{2\sigma^2} \right\} \exp \left\{ -\frac{n(\bar{X} - \mu)^2}{2\sigma^2} \right\},\end{aligned}$$

где  $\bar{X} = n^{-1} \sum_i X_i$ ,  $S^2 = n^{-1} \sum_i (X_i - \bar{X})^2$ . Последнее равенство

следует из равенства  $\sum_i (X_i - \mu)^2 = nS^2 + n(\bar{X} - \mu)^2$ , которое легко

следует из  $\sum_i (X_i - \mu)^2 = \sum_i (X_i - \bar{X} + \bar{X} - \mu)^2$

$$\ell(\mu, \sigma) = -n \log \sigma - \frac{nS^2}{2\sigma^2} - \frac{n(\overline{X} - \mu)^2}{2\sigma^2}$$

Пусть  $\frac{\partial \ell(\mu, \sigma)}{\partial \mu} = 0$  и  $\frac{\partial \ell(\mu, \sigma)}{\partial \sigma} = 0$ ,

<sup>11</sup> тогда  $\hat{\mu} = \overline{X}$  и  $\hat{\sigma} = S$ .

Пример: пусть  $X_1, \dots, X_n \sim Unif(0, \theta)$ .

$$f(x; \theta) = \begin{cases} 1/\theta, & x \in (0, \theta) \\ 0, & x \notin (0, \theta) \end{cases}$$


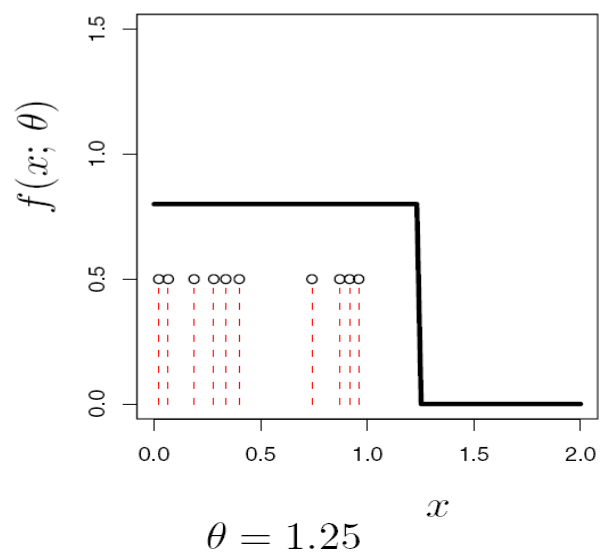
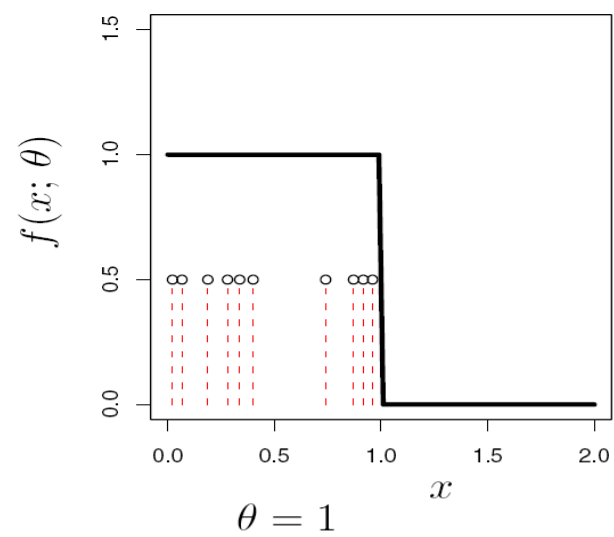
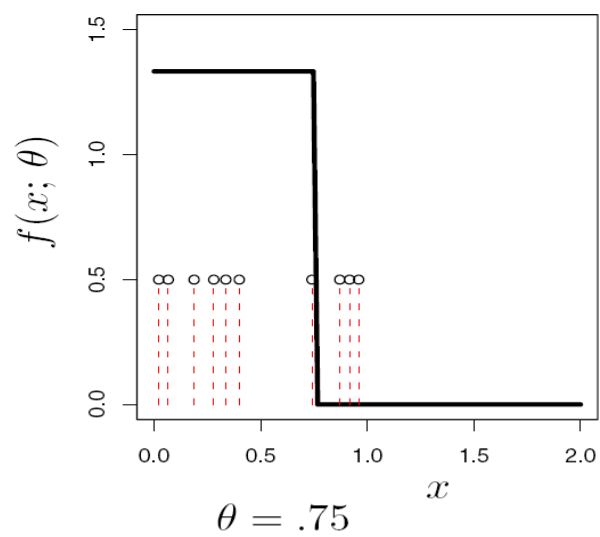
Рассмотрим фиксированное значение  $\theta$ . Допустим, что  $\theta < X_i$  для некоторого  $i$ . Тогда  $f(X_i; \theta) = 0$ , поэтому  $\mathcal{L}_n(\theta) = \prod_i f(X_i; \theta) = 0$ .

Таким образом,  $\mathcal{L}_n(\theta) = 0$  если  $X_i > \theta$  хотя бы для одного  $i$ , то есть  $\mathcal{L}_n(\theta) = 0$  при  $\theta < X_{(n)}$ , где  $X_{(n)} = \max\{X_1, \dots, X_n\}$ .

Рассмотрим произвольное  $\theta \geq X_{(n)}$ . Тогда  $f(X_i; \theta) = 1/\theta$  для любого  $i$  и  $\mathcal{L}_n(\theta) = \prod_i f(X_i; \theta) = \theta^{-n}$ . Таким образом,

$$\mathcal{L}_n(\theta) = \begin{cases} \left(\frac{1}{\theta}\right)^n & \theta \geq X_{(n)} \\ 0 & \theta < X_{(n)} \end{cases}$$

Так как  $\mathcal{L}_n(\theta)$  строго убывающая функция параметра  $\theta$  на интервале  $[X_{(n)}, \infty)$ , то  $\hat{\theta}_n = X_{(n)}$



## Свойства функции правдоподобия:

1.ОМП состоятельная, то есть  $\hat{\theta}_n \xrightarrow{P} \theta_*$ , где  $\theta_*$  - реальное значение параметра  $\theta$

2.ОМП не зависит от параметризации, то есть  $\hat{\theta}_n$  - ОМП для  $\theta$ , тогда  $g(\hat{\theta}_n)$  - ОМП для  $g(\theta)$

3.ОМП асимптотически нормальна -  $(\hat{\theta} - \theta_*)/\hat{se} \rightsquigarrow N(0, 1)$

4.ОМП асимптотически оптимальна или эффективна (при достаточно большом объеме выборки ОМП имеет меньшую дисперсию)

5.ОМП приближенно совпадает с байесовской оценкой

Замечание: вышеприведенные свойства ОМП имеют место, если функция  $f(x; \theta)$  достаточно регулярная. В «слишком» сложных случаях ОМП оценка «теряет» эти свойства

## Состоятельность ОМП

$$D(f, g) = \int f(x) \log \left( \frac{f(x)}{g(x)} \right) dx,$$

Расстояния Кульбака-Лейблера

где  $f$  и  $g$  - плотности распределений (это не расстояние в обычном смысле, так как функционал не симметричен)

16

Можно показать, что  $D(f, g) \geq 0$  и  $D(f, f) = 0$ . Будем писать  $D(\theta, \psi)$  для  $\theta, \psi \in \Theta$  вместо  $D(f(x; \theta), f(x; \psi))$ .

Будем говорить, что модель  $\mathcal{F}$  идентифицируема, если из  $\theta \neq \psi$  следует, что  $D(\theta, \psi) > 0$



**Максимизация  $\ell_n(\theta)$  эквивалентна максимизации**

$$M_n(\theta) = \frac{1}{n} \sum_i \log \frac{f(X_i; \theta)}{f(X_i; \theta_*)},$$

**поскольку  $M_n(\theta) = n^{-1}(\ell_n(\theta) - \ell_n(\theta_*))$  и  $\ell_n(\theta_*)$  - константа**

$$\begin{aligned} 17 \quad \mathbb{E}_{\theta_*} \left( \log \frac{f(X_i; \theta)}{f(X_i; \theta_*)} \right) &= \int \log \left( \frac{f(x; \theta)}{f(x; \theta_*)} \right) f(x; \theta_*) dx \\ &= - \int \log \left( \frac{f(x; \theta_*)}{f(x; \theta)} \right) f(x; \theta_*) dx \\ &= -D(\theta_*, \theta) \end{aligned}$$

**Таким образом,  $M_n(\theta) \approx -D(\theta_*, \theta)$  принимает максимальное значение в точке  $\theta_*$ , поскольку  $-D(\theta_*, \theta_*) = 0$  и  $-D(\theta_*, \theta) < 0$  при  $\theta \neq \theta_*$**

**Теорема.** Пусть  $\theta_*$  - реальное значение параметра  $\theta$ . Обозначим через

$$M_n(\theta) = \frac{1}{n} \sum_i \log \frac{f(X_i; \theta)}{f(X_i; \theta_*)}$$

и  $M(\theta) = -D(\theta_*, \theta)$ . Допустим, что

18 
$$\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{P} 0$$

и для каждого  $\epsilon > 0$

$$\sup_{\theta: |\theta - \theta_*| \geq \epsilon} M(\theta) < M(\theta_*)$$

Пусть  $\hat{\theta}_n$  обозначает ОМП. Тогда  $\hat{\theta}_n \xrightarrow{P} \theta_*$

**Доказательство.** Так как  $\hat{\theta}_n$  максимизирует  $M_n(\theta)$ , то  $M_n(\hat{\theta}_n) \geq M_n(\theta_*)$ . Следовательно,

$$\begin{aligned}
 M(\theta_*) - M(\hat{\theta}_n) &= M_n(\theta_*) - M(\hat{\theta}_n) + M(\theta_*) - M_n(\theta_*) \\
 &\leq M_n(\hat{\theta}_n) - M(\hat{\theta}_n) + M(\theta_*) - M_n(\theta_*) \\
 &\leq \sup_{\theta} |M_n(\theta) - M(\theta)| + M(\theta_*) - M_n(\theta_*) \\
 &\xrightarrow{\text{P}} 0
 \end{aligned}$$

Таким образом, для любого  $\delta > 0$

$$\mathbb{P} \left( M(\hat{\theta}_n) < M(\theta_*) - \delta \right) \rightarrow 0$$

Возьмем произвольное  $\epsilon > 0$ . Согласно условию теоремы найдется  $\delta > 0$ , для которого из неравенства  $|\theta - \theta_\star| \geq \epsilon$  следует, что

$$M(\theta) < M(\theta_\star) - \delta.$$

Значит,

$$20 \quad \mathbb{P}(|\hat{\theta}_n - \theta_\star| > \epsilon) \leq \mathbb{P}\left(M(\hat{\theta}_n) < M(\theta_\star) - \delta\right) \rightarrow 0$$

## ОМП не зависит от параметризации

**Теорема.** Пусть  $\tau = g(\theta)$  - функция параметра  $\theta$ ,  $\hat{\theta}_n$  - ОМП  $\theta$ . Тогда  $\hat{\tau}_n = g(\hat{\theta}_n)$  является ОМП для  $\tau = g(\theta)$ .

21 **Доказательство.**

Обозначим через  $h = g^{-1}$  - обратную функцию к  $g$ . Тогда  $\hat{\theta}_n = h(\hat{\tau}_n)$ .  
Для любого  $\tau$  будет выполнено, что

$$\mathcal{L}(\tau) = \prod_i f(x_i; h(\tau)) = \prod_i f(x_i; \theta) = \mathcal{L}(\theta),$$

где  $\theta = h(\tau)$ . Следовательно, для любого  $\tau$

$$\mathcal{L}_n(\tau) = \mathcal{L}(\theta) \leq \mathcal{L}(\hat{\theta}) = \mathcal{L}_n(\hat{\tau})$$

**Пример.** Пусть  $X_1, \dots, X_n \sim N(\theta, 1)$ . ОМП для  $\theta$  равна  $\hat{\theta}_n = \bar{X}_n$ .  
 Пусть  $\tau = e^\theta$ . Тогда ОМП для  $\tau$  равняется  $\hat{\tau} = e^{\hat{\theta}} = e^{\bar{X}}$ .

### **Асимптотическая нормальность ОМП**

22 Пусть  $s(X; \theta) = \frac{\partial \log f(X; \theta)}{\partial \theta}$ . Тогда информация Фишера равняется

$$\begin{aligned} I_n(\theta) &= \mathbb{V}_\theta \left( \sum_{i=1}^n s(X_i; \theta) \right) \\ &= \sum_{i=1}^n \mathbb{V}_\theta (s(X_i; \theta)) \end{aligned}$$

**Лемма.**  $\mathbb{E}_\theta(s(X; \theta)) = 0$  и  $\mathbb{V}_\theta(s(X; \theta)) = \mathbb{E}_\theta(s^2(X; \theta))$

**Доказательство.**

Очевидно,  $1 = \int f(x; \theta) dx$

$$0 = \frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx$$

23

$$= \int \frac{\frac{\partial f(x; \theta)}{\partial \theta}}{f(x; \theta)} f(x; \theta) dx = \int \frac{\partial \log f(x; \theta)}{\partial \theta} f(x; \theta) dx$$

$$= \int s(x; \theta) f(x; \theta) dx = \mathbb{E}_\theta s(X; \theta)$$

**Теорема.**  $I_n(\theta) = nI(\theta)$ , при этом

$$\begin{aligned} I(\theta) &= -\mathbb{E}_\theta \left( \frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right) \\ &= -\int \left( \frac{\partial^2 \log f(x; \theta)}{\partial \theta^2} \right) f(x; \theta) dx \end{aligned}$$



**Теорема** (асимптотическая нормальность ОМП). Пусть  $se = \sqrt{\mathbb{V}(\hat{\theta}_n)}$ .  
 При достаточно общих условиях регулярности на плотность распределения  
 выборки будет выполнено, что

1.  $se \approx \sqrt{1/I_n(\theta)}$  и

$$\frac{(\hat{\theta}_n - \theta)}{se} \rightsquigarrow N(0, 1)$$

2. Пусть  $\hat{se} = \sqrt{1/I_n(\hat{\theta}_n)}$ , тогда

$$\frac{(\hat{\theta}_n - \theta)}{\hat{se}} \rightsquigarrow N(0, 1)$$

**Доказательство.**

Пусть  $\ell(\theta) = \log \mathcal{L}(\theta)$ . Тогда

$$0 = \ell'(\hat{\theta}) \approx \ell'(\theta) + (\hat{\theta} - \theta)\ell''(\theta)$$

Отсюда получаем, что

$$\hat{\theta} - \theta = -\ell'(\theta)/\ell''(\theta)$$

26

$$\sqrt{n}(\hat{\theta} - \theta) = \frac{\frac{1}{\sqrt{n}}\ell'(\theta)}{-\frac{1}{n}\ell''(\theta)} \quad (*)$$

Пусть  $Y_i = \partial \log f(X_i; \theta) / \partial \theta$ . Из леммы следует, что  $\mathbb{E}(Y_i) = 0$  и  $\mathbb{V}(Y_i) = I(\theta)$ . Значит, для числителя в (\*) выполняется, что

$$n^{-1/2} \sum_i Y_i = \sqrt{n} \bar{Y} = \sqrt{n}(\bar{Y} - 0) \rightsquigarrow W \sim N(0, I(\theta))$$

**Положим**  $A_i = -\partial^2 \log f(X_i; \theta) / \partial \theta^2$ . Тогда  $\mathbb{E}(A_i) = I(\theta)$  и для знаменателя в (\*) выполняется, что  $\overline{A} \xrightarrow{P} I(\theta)$ . Итак,

$$\sqrt{n}(\hat{\theta} - \theta) \rightsquigarrow \frac{W}{I(\theta)} \stackrel{d}{=} N\left(0, \frac{1}{I(\theta)}\right)$$

27 **Предположим, что**  $I(\theta)$  **- непрерывная функция своего аргумента. Тогда**  
 $I(\hat{\theta}_n) \xrightarrow{P} I(\theta)$  **и**

$$\begin{aligned} \frac{\hat{\theta}_n - \theta}{\widehat{\text{se}}} &= \sqrt{n} I^{1/2}(\hat{\theta}_n) (\hat{\theta}_n - \theta) \\ &= \left\{ \sqrt{n} I^{1/2}(\theta) (\hat{\theta}_n - \theta) \right\} \sqrt{\frac{I(\hat{\theta}_n)}{I(\theta)}} \end{aligned}$$

Первый множитель стремится по распределению к  $N(0,1)$ , второй множитель – к единице, ч.т.д.

**Теорема.** Пусть

$$C_n = \left( \hat{\theta}_n - z_{\alpha/2} \hat{s}e, \hat{\theta}_n + z_{\alpha/2} \hat{s}e \right)$$

28

Тогда  $\mathbb{P}_{\theta}(\theta \in C_n) \rightarrow 1 - \alpha$  при  $n \rightarrow \infty$ .

**Доказательство.** Обозначим через  $Z$  - стандартно нормально распределенную случайную величину.

$$\begin{aligned}
\mathbb{P}_\theta(\theta \in C_n) &= \mathbb{P}_\theta \left( \hat{\theta}_n - z_{\alpha/2} \hat{\text{se}} \leq \theta \leq \hat{\theta}_n + z_{\alpha/2} \hat{\text{se}} \right) \\
&= \mathbb{P}_\theta \left( -z_{\alpha/2} \leq \frac{\hat{\theta}_n - \theta}{\hat{\text{se}}} \leq z_{\alpha/2} \right) \\
&\rightarrow \mathbb{P}(-z_{\alpha/2} < Z < z_{\alpha/2}) = 1 - \alpha
\end{aligned}$$

<sup>29</sup> Для  $\alpha = .05$ ,  $z_{\alpha/2} = 1.96 \approx 2$ , поэтому

$$\hat{\theta}_n \pm 2 \hat{\text{se}}$$

приблизленно задают границы 95% доверительного интервала

**Пример.** Пусть  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ . ОМП равна  $\hat{p}_n = \sum_i X_i / n$ .

$$f(x; p) = p^x (1 - p)^{1-x}, \log f(x; p) = x \log p + (1 - x) \log(1 - p)$$

$$s(X; p) = \frac{X}{p} - \frac{1 - X}{1 - p}$$

$$-s'(X; p) = \frac{X}{p^2} + \frac{1 - X}{(1 - p)^2}$$

$$I(p) = \mathbb{E}_p(-s'(X; p)) = \frac{p}{p^2} + \frac{(1 - p)}{(1 - p)^2} = \frac{1}{p(1 - p)}$$

$$\widehat{\text{se}} = \frac{1}{\sqrt{I_n(\widehat{p}_n)}} = \frac{1}{\sqrt{nI(\widehat{p}_n)}} = \left\{ \frac{\widehat{p}(1 - \widehat{p})}{n} \right\}^{1/2}$$

$$\widehat{p}_n \pm 2 \left\{ \frac{\widehat{p}_n(1 - \widehat{p}_n)}{n} \right\}^{1/2}$$

**приближенно задают границы 95% доверительного интервала**

**Пример.** Пусть  $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ , где  $\sigma^2$  - известно.

$$s(X; \theta) = (X - \theta) / \sigma^2$$

$$s'(X; \theta) = -1 / \sigma^2$$

$$I_1(\theta) = 1 / \sigma^2$$

$$\hat{\theta}_n = \overline{X}_n$$

$$\overline{X}_n \approx N(\theta, \sigma^2 / n)$$

(\*)

На самом деле в (\*) распределение в точности нормальное.

**Пример.** Пусть  $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$ . Тогда  $\hat{\lambda}_n = \bar{X}_n$  и  $I_1(\lambda) = 1/\lambda$ . Откуда

$$\widehat{\text{se}} = \frac{1}{\sqrt{nI(\hat{\lambda}_n)}} = \sqrt{\frac{\hat{\lambda}_n}{n}}$$

Таким образом,

$$\hat{\lambda}_n \pm z_{\alpha/2} \sqrt{\hat{\lambda}_n/n}$$

приблизленно задают границы 95% доверительного интервала



## Оптимальность и эффективность ОМП

Пусть  $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ . ОМП для  $\theta$  равна  $\hat{\theta}_n = \overline{X}_n$ .

Обозначим через  $\tilde{\theta}_n$  - выборочную медиану, которую также можно  
33 использовать для оценки  $\theta$ .

$$\sqrt{n}(\hat{\theta}_n - \theta) \rightsquigarrow N(0, \sigma^2)$$

$$\sqrt{n}(\tilde{\theta}_n - \theta) \rightsquigarrow N\left(0, \sigma^2 \frac{\pi}{2}\right)$$

В более общем случае, рассмотрим две оценки  $T_n$  и  $U_n$ . Будем предполагать, что

$$\sqrt{n}(T_n - \theta) \rightsquigarrow N(0, t^2)$$

$$\sqrt{n}(U_n - \theta) \rightsquigarrow N(0, u^2)$$

Определим асимптотическую относительную эффективность  $U_n$  к  $T_n$  по формуле  $\text{ARE}(U, T) = t^2/u^2$ . В рассмотренном случае  $\text{ARE}(\tilde{\theta}_n, \hat{\theta}_n) = 2/\pi = .63$ . Интерпретация состоит в том, что асимптотическая относительная эффективность показывает долю данных, 34 которые используются при оценке параметра.

Теорема. Пусть  $\hat{\theta}_n$  - ОМП,  $\tilde{\theta}_n$  - какая-то другая оценка. Тогда при соответствующих условиях регулярности (в предположении, что используемая параметрическая модель верна), будет выполнено, что

$$\text{ARE}(\tilde{\theta}_n, \hat{\theta}_n) \leq 1$$

Таким образом, ОМП имеет наименьшую асимптотическую дисперсию, то есть ОМП эффективна/асимптотически оптимальна

### с) Дельта-метод

Пусть  $\tau = g(\theta)$ , где  $g$  - гладкая функция. ОМП для  $\tau$  равняется  $\hat{\tau} = g(\hat{\theta})$ . Каково распределение  $\hat{\tau}$ ?

35 Теорема. Если  $\tau = g(\theta)$ , где  $g$  - дифференцируемая и  $g'(\theta) \neq 0$ , то

$$\frac{(\hat{\tau}_n - \tau)}{\hat{\text{se}}(\hat{\tau})} \rightsquigarrow N(0, 1),$$

где  $\hat{\tau}_n = g(\hat{\theta}_n)$  и  $\hat{\text{se}}(\hat{\tau}_n) = |g'(\hat{\theta})| \hat{\text{se}}(\hat{\theta}_n)$ . Пусть

$$C_n = \left( \hat{\tau}_n - z_{\alpha/2} \hat{\text{se}}(\hat{\tau}_n), \hat{\tau}_n + z_{\alpha/2} \hat{\text{se}}(\hat{\tau}_n) \right),$$

тогда  $\mathbb{P}_{\theta}(\tau \in C_n) \rightarrow 1 - \alpha$  и  $n \rightarrow \infty$

**Доказательство.**

$$\hat{\tau}_n = g(\hat{\theta}_n) \approx g(\theta) + (\hat{\theta}_n - \theta)g'(\theta) = \tau + (\hat{\theta}_n - \theta)g'(\theta)$$

$$\sqrt{n}(\hat{\tau}_n - \tau) \approx \sqrt{n}(\hat{\theta}_n - \theta)g'(\theta)$$

$$\frac{\sqrt{nI(\theta)}(\hat{\tau}_n - \tau)}{g'(\theta)} \approx \sqrt{nI(\theta)}(\hat{\theta}_n - \theta)$$

36 Правая часть последней формулы стремится по распределению к  $N(0,1)$

Следовательно,  $\frac{\sqrt{nI(\theta)}(\hat{\tau}_n - \tau)}{g'(\theta)} \rightsquigarrow N(0,1)$ , откуда

$$\hat{\tau}_n \approx N(\tau, \text{se}^2(\hat{\tau}_n)),$$

$$\text{se}^2(\hat{\tau}_n) = \frac{(g'(\theta))^2}{nI(\theta)}$$

где

Очевидно, что результат не изменится, если  $\theta$  заменить на  $\hat{\theta}_n$ .

**Пример.** Пусть  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ ,  $\psi = g(p) = \log(p/(1-p))$ .

Информация Фишера равна  $I(p) = 1/(p(1-p))$ . Оценка стандартной ошибки для  $\hat{p}_n$  равна

$$\widehat{\text{se}} = \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}$$

37

ОМП величины  $\psi$  равна  $\hat{\psi} = \log \hat{p}/(1-\hat{p})$ . Так как  $g'(p) = 1/(p(1-p))$ , то в соответствии с дельта-методом

$$\widehat{\text{se}}(\hat{\psi}_n) = |g'(\hat{p}_n)|\widehat{\text{se}}(\hat{p}_n) = \frac{1}{\sqrt{n\hat{p}_n(1-\hat{p}_n)}}$$

Таким образом, границы приближенного 95% доверительного интервала равны

$$\hat{\psi}_n \pm \frac{2}{\sqrt{n\hat{p}_n(1-\hat{p}_n)}}$$

**Пример.** Пусть  $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ . Допустим, что  $\mu$  известно, а  $\sigma$  - неизвестно и необходимо оценить  $\psi = \log \sigma$ . Логарифм функции правдоподобия равен  $\ell(\sigma) = -n \log \sigma - \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2$ , значит

$$\hat{\sigma}_n = \sqrt{\frac{\sum_i (X_i - \mu)^2}{n}}$$

Для того, чтобы подсчитать стандартную ошибку, необходимо знать  
38 информацию Фишера.

$$\log f(X; \sigma) = -\log \sigma - \frac{(X - \mu)^2}{2\sigma^2}$$

Вторая производная логарифма плотности равна

$$\frac{1}{\sigma^2} - \frac{3(X - \mu)^2}{\sigma^4}$$

Значит,

$$I(\sigma) = -\frac{1}{\sigma^2} + \frac{3\sigma^2}{\sigma^4} = \frac{2}{\sigma^2}$$

Таким образом,  $\widehat{\text{se}} = \widehat{\sigma}_n / \sqrt{2n}$ . Пусть  $\psi = g(\sigma) = \log \sigma$ , тогда  $\widehat{\psi}_n = \log \widehat{\sigma}_n$ . Так как  $g' = 1/\sigma$ , то

$$\widehat{\text{se}}(\widehat{\psi}_n) = \frac{1}{\widehat{\sigma}_n} \frac{\widehat{\sigma}_n}{\sqrt{2n}} = \frac{1}{\sqrt{2n}}$$

Итак, границы приближенного 95% доверительного интервала равны

$$\widehat{\psi}_n \pm 2/\sqrt{2n}$$

**d) Случай векторного параметра (многопараметрический дельта-метод)**

Пусть  $\theta = (\theta_1, \dots, \theta_k)$  и  $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$  - ОМП для  $\theta$ ,

$$\ell_n = \sum_{i=1}^n \log f(X_i; \theta)$$

$$H_{jj} = \frac{\partial^2 \ell_n}{\partial \theta_j^2} \text{ и } H_{jk} = \frac{\partial^2 \ell_n}{\partial \theta_j \partial \theta_k}$$

Обозначим

Информационная матрица Фишера имеет вид

$$I_n(\theta) = - \begin{bmatrix} \mathbb{E}_\theta(H_{11}) & \mathbb{E}_\theta(H_{12}) & \cdots & \mathbb{E}_\theta(H_{1k}) \\ \mathbb{E}_\theta(H_{21}) & \mathbb{E}_\theta(H_{22}) & \cdots & \mathbb{E}_\theta(H_{2k}) \\ \vdots & \vdots & \vdots & \vdots \\ \mathbb{E}_\theta(H_{k1}) & \mathbb{E}_\theta(H_{k2}) & \cdots & \mathbb{E}_\theta(H_{kk}) \end{bmatrix}$$

Пусть также  $J_n(\theta) = I_n^{-1}(\theta)$



**Теорема.** При соответствующих условиях регулярности

$$(\hat{\theta} - \theta) \approx N(0, J_n)$$

Также, если  $\hat{\theta}_j$  -  $j$ -я компонента вектора  $\hat{\theta}$ , то

$$\frac{(\hat{\theta}_j - \theta_j)}{\hat{\text{se}}_j} \rightsquigarrow N(0, 1)$$

41 где  $\hat{\text{se}}_j^2 = J_n(j, j)$  -  $j$ -й диагональный элемент матрицы  $J_n$ . Приблизненно ковариация между  $\hat{\theta}_j$  и  $\hat{\theta}_k$  равна  $\text{Cov}(\hat{\theta}_j, \hat{\theta}_k) \approx J_n(j, k)$ .

Пусть  $\tau = g(\theta_1, \dots, \theta_k)$  - функция параметра,

$$\nabla g = \begin{pmatrix} \frac{\partial g}{\partial \theta_1} \\ \vdots \\ \frac{\partial g}{\partial \theta_k} \end{pmatrix}$$

**Теорема.** Допустим, что значение  $\nabla g$  в точке  $\hat{\theta}$ , не равно 0. Положим  $\hat{\tau} = g(\hat{\theta})$ , тогда

$$\frac{(\hat{\tau} - \tau)}{\widehat{\text{se}}(\hat{\tau})} \rightsquigarrow N(0, 1), \text{ где}$$

$$\widehat{\text{se}}(\hat{\tau}) = \sqrt{(\hat{\nabla} g)^T \hat{J}_n (\hat{\nabla} g)}$$

42

$\hat{J}_n = J_n(\hat{\theta}_n)$  и  $\hat{\nabla} g$  равняется значению  $\nabla g$  в точке  $\theta = \hat{\theta}$ .

**Пример.** Пусть  $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ,  $\tau = g(\mu, \sigma) = \sigma/\mu$   
**Несложно показать, что**

$$I_n(\mu, \sigma) = \begin{bmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{2n}{\sigma^2} \end{bmatrix}$$

**Тогда**

$$J_n = I_n^{-1}(\mu, \sigma) = \frac{1}{n} \begin{bmatrix} \sigma^2 & 0 \\ 0 & \frac{\sigma^2}{2} \end{bmatrix}$$

**Очевидно, что**

$$\nabla g = \begin{pmatrix} -\frac{\sigma}{\mu^2} \\ \frac{1}{\mu} \end{pmatrix}$$

**Значит,**

$$\widehat{\text{se}}(\widehat{\tau}) = \sqrt{(\widehat{\nabla} g)^T \widehat{J}_n (\widehat{\nabla} g)} = \frac{1}{\sqrt{n}} \sqrt{\frac{1}{\widehat{\mu}^4} + \frac{\widehat{\sigma}^2}{2\widehat{\mu}^2}}$$

### е) Параметрический бутстреп

В непараметрическом случае псевдовыборка  $X_1^*, \dots, X_n^*$  генерировалась распределенной согласно распределению  $\hat{F}_n$ . В данном случае псевдовыборка будет генерироваться распределенной с плотностью  $f(x; \hat{\theta}_n)$

44 Пример. Допустим, то в модели  $X_1, \dots, X_n \sim N(\mu, \sigma^2)$  получены ОМП. Чтобы подсчитать стандартные ошибки можно поступить следующим образом. Генерируется псевдовыборка  $X_1^*, \dots, X_n^* \sim N(\hat{\mu}, \hat{\sigma}^2)$ , подсчитывается величина  $\hat{\tau}^* = g(\hat{\mu}^*, \hat{\sigma}^*) = \hat{\sigma}^* / \hat{\mu}^*$ . Подсчеты повторяются  $B$  раз, подсчитываются величины  $\hat{\tau}_1^*, \dots, \hat{\tau}_B^*$ . Оценка стандартной ошибки равна

$$\hat{\text{se}}_{\text{boot}} = \sqrt{\frac{\sum_{b=1}^B (\hat{\tau}_b^* - \hat{\tau})^2}{B}}$$

## f) Достаточная статистика

Статистика  $T(X^n)$  - сигма-измеримая функция выборки

Будем писать  $x^n \leftrightarrow y^n$  если  $f(x^n; \theta) = c f(y^n; \theta)$  для некоторой константы  $c$ , которая может зависеть от  $x^n$  и  $y^n$  но не от  $\theta$ . Статистика  $T(x^n)$  называется достаточной, если из того, что  $T(x^n) \leftrightarrow T(y^n)$ ,  
45 следует, что  $x^n \leftrightarrow y^n$ .

Грубо говоря, статистика  $T(X^n)$  достаточная, если мы можем подсчитать функцию правдоподобия, зная только значение  $T(X^n)$

**Пример.** Пусть  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ . Тогда

$$\mathcal{L}(p) = p^S (1 - p)^{n-S}$$

и статистика  $S = \sum_i X_i$  достаточная

46 **Пример.** Пусть  $X_1, \dots, X_n \sim N(\mu, \sigma)$  и  $T = (\bar{X}, S)$ . Тогда

$$f(X^n; \mu, \sigma) = \left( \frac{1}{\sigma \sqrt{2\pi}} \right)^n \exp \left\{ -\frac{nS^2}{2\sigma^2} \right\} \exp \left\{ -\frac{n(\bar{X} - \mu)^2}{2\sigma^2} \right\}$$

$$T_1(X^n) = (X_1, \dots, X_n)$$

$$T_2(X^n) = (\bar{X}, S)$$

$$T_3(X^n) = \bar{X}$$

$$T_4(X^n) = (\bar{X}, S, X_3)$$

Статистика  $T$  является достаточной статистикой минимальной размерности, если а)  $T$  - достаточная статистика б)  $T$  является функцией любой другой достаточной статистики

Теорема.  $T$  является достаточной статистикой минимальной размерности  
47 если выполнено:  $T(x^n) = T(y^n)$  если и только если  $x^n \leftrightarrow y^n$

Значения статистики разбивают множество исходов на классы. О достаточности статистики можно рассуждать в терминах этих классов

**Пример.**  $X_1, X_2 \sim \text{Bernoulli}(\theta)$ . Пусть  $V = X_1$ ,  $T = \sum_i X_i$  и  $U = (T, X_1)$ .

$X_1$	$X_2$	$V$	$T$	$U$
0	0	0	0	(0,0)
0	1	0	1	(1,0)
1	0	1	1	(1,1)
1	1	1	2	(2,1)

$$V \longrightarrow \{(0,0), (0,1)\}, \{(1,0), (1,1)\}$$

$$T \longrightarrow \{(0,0)\}, \{(0,1), (1,0)\}, \{(1,1)\}$$

$$U \longrightarrow \{(0,0)\}, \{(0,1)\}, \{(1,0)\}, \{(1,1)\}$$

$V$  - не достаточная статистика;  $T$  и  $U$  - достаточные статистики;  $U$  - статистика не минимальной размерности, поскольку если  $x^n = (1,0)$  и  $y^n = (0,1)$ , то  $x^n \leftrightarrow y^n$ , однако  $U(x^n) \neq U(y^n)$



**Пример.** Для модели  $N(\mu, \sigma^2)$  статистика  $T = (\bar{X}, S)$  - минимальная достаточная. Для пуассоновской и бернуллиевской моделей  $T = \sum_i X_i$  - минимальная достаточная статистика. Статистика  $T = (\sum_i X_i, X_1)$  - достаточная, но не минимальной размерности. Статистика  $T = X_1$  - не достаточная.

49 **Определение.** Статистика  $T$  является достаточной, если распределение выборки при заданном значении  $T(X^n) = t$  не зависит от  $\theta$ , то есть

$$f(x_1, \dots, x_n | t; \theta) = h(x_1, \dots, x_n, t)$$

**Пример.**  $T = \sum_i X_i$  является достаточной для пуассоновского распределения

**Теорема.**  $T$  является достаточной iff найдутся функции  $g(t, \theta)$  и  $h(x)$ , что  $f(x^n; \theta) = g(t(x^n), \theta)h(x^n)$ .

**Пример.**  $X = (X_1, X_2) \sim \text{Bernoulli}(p)$ ,  $T = X_1 + X_2$  - достаточная статистика. Проверка «в лоб»:

а)  $T = 0$

$$P(X_1 = 0, X_2 = 0|t = 0) = 1, P(X_1 = 0, X_2 = 1|t = 0) = 0,$$

$$P(X_1 = 1, X_2 = 0|t = 0) = 0, P(X_1 = 1, X_2 = 1|t = 0) = 0;$$

50 б)  $T = 1$

$$P(X_1 = 0, X_2 = 0|t = 1) = 0, P(X_1 = 0, X_2 = 1|t = 1) = \frac{1}{2},$$

$$P(X_1 = 1, X_2 = 0|t = 1) = \frac{1}{2}, P(X_1 = 1, X_2 = 1|t = 1) = 0;$$

в)  $T = 2$

$$P(X_1 = 0, X_2 = 0|t = 2) = 0, P(X_1 = 0, X_2 = 1|t = 2) = 0,$$

$$P(X_1 = 1, X_2 = 0|t = 2) = 0, P(X_1 = 1, X_2 = 1|t = 2) = 1.$$

## Проверка с помощью критерия факторизации

Пусть  $t = x_1 + x_2$ , тогда

$$\begin{aligned} f(x_1, x_2; \theta) &= f(x_1; \theta) f(x_2; \theta) \\ &= \theta^{x_1} (1 - \theta)^{1-x_1} \theta^{x_2} (1 - \theta)^{1-x_2} \\ &= g(t, \theta) h(x_1, x_2), \text{ где} \end{aligned}$$

51

$$g(t, \theta) = \theta^t (1 - \theta)^{2-t} \text{ и } h(x_1, x_2) = 1$$

Пусть  $\hat{\theta}$  - оценка параметра  $\theta$ ,  $R(\theta, \hat{\theta}) = \mathbb{E}_\theta (\theta - \hat{\theta})^2$  - MSE

**Теорема** (Блекуэлла-Рао-Колмогорова). Пусть  $\hat{\theta}$  - оценка параметра  $\theta$ ,  $T$  - достаточная статистика. Получим новую оценку параметра  $\theta$  по формуле

$$\tilde{\theta} = \mathbb{E}(\hat{\theta}|T)$$

Тогда для каждого  $\theta$ ,  $R(\theta, \tilde{\theta}) \leq R(\theta, \hat{\theta})$

52

**Пример.**  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ ,  $T = \sum_i X_i$

$\hat{\theta} = X_1$  - несмещенная, но не состоятельная оценка

$$\tilde{\theta} = \mathbb{E}(X_1|T) = n^{-1} \sum_i X_i$$

**g) Экспоненциальное семейство распределений**

$\{f(x; \theta) : \theta \in \Theta\}$  - **однопараметрическое экспоненциальное семейство распределений**, если найдутся функции  $\eta(\theta)$ ,  $B(\theta)$ ,  $T(x)$  и  $h(x)$ , такие, что

$$f(x; \theta) = h(x)e^{\eta(\theta)T(x) - B(\theta)}$$

53

**Очевидно, что при этом  $T(X)$  - достаточная статистика**

**Пример.** Пусть  $X \sim \text{Poisson}(\theta)$ , тогда

$$f(x; \theta) = \frac{\theta^x e^{-\theta}}{x!} = \frac{1}{x!} e^{x \log \theta - \theta}$$

**- принадлежит экспоненциальному семейству при  $\eta(\theta) = \log \theta$ ,  $B(\theta) = \theta$ ,  $T(x) = x$**

**Пример.** Пусть  $X \sim \text{Binomial}(n, \theta)$

$$f(x; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} = \binom{n}{x} \exp \left\{ x \log \left( \frac{\theta}{1 - \theta} \right) + n \log(1 - \theta) \right\}$$

$$\eta(\theta) = \log \left( \frac{\theta}{1 - \theta} \right), B(\theta) = -n \log(\theta)$$

54

$$T(x) = x, h(x) = \binom{n}{x}$$

**Экспоненциальное семейство можно записать в виде**

$$f(x; \eta) = h(x) e^{\eta T(x) - A(\eta)}, \text{ где}$$

$$A(\eta) = \log \int h(x) e^{\eta T(x)} dx$$

Пусть  $X_1, \dots, X_n$  - i.i.d. выборка из экспоненциального семейства. Тогда распределение выборки  $f(x^n; \theta)$  также будет принадлежать экспоненциальному семейству

$$f(x^n; \theta) = h_n(x^n) h_n(x^n) e^{\eta(\theta) T_n(x^n) - B_n(\theta)}$$

$$h_n(x^n) = \prod_i h(x_i), \quad T_n(x^n) = \sum_i T(x_i)$$

$$B_n(\theta) = nB(\theta)$$

Таким образом, статистика  $\sum_i T(X_i)$  будет достаточной

**Пример.** Пусть  $X_1, \dots, X_n \sim \text{Uniform}(0, \theta)$ . Тогда

$$f(x^n; \theta) = \frac{1}{\theta^n} I(x_{(n)} \leq \theta), \text{ где}$$

$x_{(n)} = \max\{x_1, \dots, x_n\}$ . Таким образом,  $T(X^n) = \max\{X_1, \dots, X_n\}$  —

достаточная статистика. Так как  $T(X^n) \neq \sum_i T(X_i)$ , то равномерное

56 распределение не принадлежит экспоненциальному семейству

**Теорема.** Пусть плотность с.в.  $X$  принадлежит экспоненциальному семейству. Тогда

$$\mathbb{E}(T(X)) = A'(\eta), \quad \mathbb{V}(T(X)) = A''(\eta)$$



Если  $\theta = (\theta_1, \dots, \theta_k)$  - вектор параметров, то плотность  $f(x; \theta)$  принадлежит экспоненциальному семейству, если

$$f(x; \theta) = h(x) \exp \left\{ \sum_{j=1}^k \eta_j(\theta) T_j(x) - B(\theta) \right\}$$

Аналогично, векторная функция  $T = (T_1, \dots, T_k)$  является достаточной статистикой. Простая выборка объема  $n$  также будет иметь плотность из экспоненциального распределения, причем достаточная статистика будет иметь вид  $(\sum_i T_1(X_i), \dots, \sum_i T_k(X_i))$

**Пример.** Рассмотрим нормальную плотность с двухмерным параметром  $\theta = (\mu, \sigma)$ . В таком случае

$$f(x; \theta) = \exp \left\{ \frac{\mu}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \frac{1}{2} \left( \frac{\mu^2}{\sigma^2} + \log(2\pi\sigma^2) \right) \right\}$$

$$\eta_1(\theta) = \frac{\mu}{\sigma^2}, \quad T_1(x) = x$$

$$\eta_2(\theta) = -\frac{1}{2\sigma^2}, \quad T_2(x) = x^2$$

$$B(\theta) = \frac{1}{2} \left( \frac{\mu^2}{\sigma^2} + \log(2\pi\sigma^2) \right), \quad h(x) = 1$$

**Статистика**  $(\sum_i X_i, \sum_i X_i^2)$  **будет достаточной**

**Как и раньше, плотность, принадлежащую экспоненциальному семейству, можно записать в виде**

$$f(x; \eta) = h(x) \exp \{ T^T(x) \eta - A(\eta) \}, \text{ где}$$

$$A(\eta) = \log \int h(x) e^{T^T(x) \eta} dx$$

**Несложно показать, что**

$$\mathbb{E}(T(X)) = \dot{A}(\eta) \quad \mathbb{V}(T(X)) = \ddot{A}(\eta)$$

## h) Максимизация функции правдоподобия

Зачастую невозможно в явном виде подсчитать значение  $\hat{\theta}$ , на котором правдоподобие достигает максимума  $\Rightarrow$  итеративные численные методы

$\Leftrightarrow$  последовательность  $\theta^0, \theta^1, \dots$ , которая при определенных условиях сходится к  $\hat{\theta}$

60 Метод Ньютона-Рафсона: разложим по Тейлору функцию правдоподобия вблизи параметра  $\theta^j$

$$0 = \ell'(\hat{\theta}) \approx \ell'(\theta^j) + (\hat{\theta} - \theta^j)\ell''(\theta^j)$$

$$\hat{\theta} \approx \theta^j - \frac{\ell'(\theta^j)}{\ell''(\theta^j)}$$

$$\hat{\theta}^{j+1} = \theta^j - \frac{\ell'(\theta^j)}{\ell''(\theta^j)}$$

В многомерном случае итерационная схема принимает вид

$$\hat{\theta}^{j+1} = \theta^j - H^{-1} \ell'(\theta^j)$$

$\ell'(\theta^j)$  - вектор первых производных,  $H$  - матрица вторых производных логарифма правдоподобия

ЕМ алгоритм: допустим, что имеется выборка  $Y$ , логарифм  
61 правдоподобия  $f(y; \theta)$  которой сложно максимизировать. Однако  
допустим, что можно найти другую случайную величину  $Z$ , что  
 $f(y; \theta) = \int f(y, z; \theta) dz$  и что логарифм правдоподобия на основе  
 $f(y, z; \theta)$  максимизировать просто

В таком случае говорят, что  $Y$  - наблюдения,  $Z$  - латентные  
(ненаблюдаемые, скрытые) данные  $\Rightarrow$  по сути надо восстановить  
пропущенные данные

**Пример** (смесь двух нормальных распределений). Пусть  $\phi(y; \mu, \sigma)$  - плотность нормального распределения с параметрами  $\mu$  и  $\sigma$ . Плотность смеси двух нормальных распределений имеет вид

$$f(y; \theta) = (1 - p)\phi(y; \mu_0, \sigma_0) + p\phi(y; \mu_1, \sigma_1)$$

$\theta = (\mu_0, \sigma_0, \mu_1, \sigma_1, p)$  - вектор параметров

62 Элемент выборки с вероятностью  $p$  принадлежит одному нормальному распределению, а с вероятностью  $1-p$  - другому

$$\mathcal{L}(\theta) = \prod_{i=1}^n [(1 - p)\phi(y_i; \mu_0, \sigma_0) + p\phi(y_i; \mu_1, \sigma_1)]$$

Допустим, что имеется «полная» информация  $(Y_1, Z_1), \dots, (Y_n, Z_n)$ , где  $\mathbb{P}(Z_i = 1) = p$ , то есть  $Z_i = 0$  означает, что соответствующее наблюдение имеет первую нормальную плотность, а  $Z_i = 1$  - вторую

### Описание ЕМ-алгоритма:

63 1. Задать начальное значение  $\theta^0$ . Для  $j = 1, 2, \dots$  повторять шаги 2 и 3 алгоритма

2. (Е-шаг) Подсчитать математическое ожидание по пропущенным данным  $Z^n$ , считая что  $\theta^j$  и  $Y^n$  - фиксированы

$$J(\theta|\theta^j) = \mathbb{E}_{\theta^j} \left( \log \frac{f(Y^n, Z^n; \theta)}{f(Y^n, Z^n; \theta^j)} \mid Y^n = y^n \right)$$

3. (М-шаг) Найти значение  $\theta^{j+1}$ , которое максимизирует  $J(\theta|\theta^j)$

Каждый шаг ЕМ-алгоритма увеличивает значение функции правдоподобия,

т.е.  $\mathcal{L}(\theta^{j+1}) \geq \mathcal{L}(\theta^j)$

$$\begin{aligned} J(\theta^{j+1}|\theta^j) &= \mathbb{E}_{\theta^j} \left( \log \frac{f(Y^n, Z^n; \theta^{j+1})}{f(Y^n, Z^n; \theta^j)} \mid Y^n = y^n \right) \\ &= \log \frac{f(y^n; \theta^{j+1})}{f(y^n; \theta^j)} + \mathbb{E}_{\theta^j} \left( \log \frac{f(Z^n|Y^n; \theta^{j+1})}{f(Z^n|Y^n; \theta^j)} \mid Y^n = y^n \right) \end{aligned}$$

$$\frac{\mathcal{L}(\theta^{j+1})}{\mathcal{L}(\theta^j)} = \log \frac{f(y^n; \theta^{j+1})}{f(y^n; \theta^j)}$$

$$= J(\theta^{j+1}|\theta^j) - \mathbb{E}_{\theta^j} \left( \log \frac{f(Z^n|Y^n; \theta^{j+1})}{f(Z^n|Y^n; \theta^j)} \mid Y^n = y^n \right)$$

$$= J(\theta^{j+1}|\theta^j) + K(f_j, f_{j+1})$$

,



где  $f_j = f(y^n; \theta^j)$ ,  $f_{j+1} = f(y^n; \theta^{j+1})$  и

$$K(f, g) = \int f(x) \log(f(x)/g(x)) dx$$

Так как  $\theta^{j+1}$  максимизирует  $J(\theta|\theta^j)$ , то  $J(\theta^{j+1}|\theta^j) \geq J(\theta^j|\theta^j) = 0$

В силу свойства расхождения Кульбака-Лейблера  $K(f_j, f_{j+1}) \geq 0$ ,

65 откуда  $\mathcal{L}(\theta^{j+1}) \geq \mathcal{L}(\theta^j)$  ч.т.д.

Пример (продолжение)

Рассмотрим случай, когда  $p = 1/2$ ,  $\sigma_1 = \sigma_2 = 1$

$$f(y; \mu_1, \mu_2) = \frac{1}{2}\phi(y; \mu_0, 1) + \frac{1}{2}\phi(y; \mu_1, 1)$$

$$f(y_i|Z_i = 0) = \phi(y; \mu_0, 1), f(y_i|Z_i = 1) = \phi(y; \mu_1, 1)$$

$$f(y) = \sum_{z=0}^1 f(y, z)$$

$$f(z, y) = f(z)f(y|z) = \frac{1}{2}\phi(y; \mu_0, 1)^{1-z}\phi(y; \mu_1, 1)^z$$

$$\prod_{i=1}^n \phi(y_i; \mu_0, 1)^{1-z_i} \phi(y_i; \mu_1, 1)^{z_i}$$

66

$$\tilde{\ell} = -\frac{1}{2} \sum_{i=1}^n (1 - z_i)(y_i - \mu_0) - \frac{1}{2} \sum_{i=1}^n z_i(y_i - \mu_1)$$

$$J(\theta|\theta^j) = -\frac{1}{2} \sum_{i=1}^n (1 - \mathbb{E}(Z_i|y^n, \theta^j))(y_i - \mu_0) - \frac{1}{2} \sum_{i=1}^n \mathbb{E}(Z_i|y^n, \theta^j)(y_i - \mu_1)$$

$$\mathbb{E}(Z_i|y^n, \theta^j) = \mathbb{P}(Z_i = 1|y^n, \theta^j)$$

$$\begin{aligned}
\mathbb{P}(Z_i = 1|y^n, \theta^i) &= \frac{f(y^n|Z_i = 1; \theta^j)\mathbb{P}(Z_i = 1)}{f(y^n|Z_i = 1; \theta^j)\mathbb{P}(Z_i = 1) + f(y^n|Z_i = 0; \theta^j)\mathbb{P}(Z_i = 0)} \\
&= \frac{\phi(y_i; \mu_1^j, 1)^{\frac{1}{2}}}{\phi(y_i; \mu_1^j, 1)^{\frac{1}{2}} + \phi(y_i; \mu_0^j, 1)^{\frac{1}{2}}} \\
&= \frac{\phi(y_i; \mu_1^j, 1)}{\phi(y_i; \mu_1^j, 1) + \phi(y_i; \mu_0^j, 1)} \\
&= \tau(i)
\end{aligned}$$

Максимизируя  $J(\theta|\theta^j)$  по параметрам  $\mu_1$  и  $\mu_2$ , получаем, что

$$\hat{\mu}_1^{j+1} = \frac{\sum_{i=1}^n \tau_i y_i}{\sum_{i=1}^n \tau_i}$$

$$\hat{\mu}_0^{j+1} = \frac{\sum_{i=1}^n (1 - \tau_i) y_i}{\sum_{i=1}^n (1 - \tau_i)}$$